

Detección de bordes

Extracto de “Visión por Computador. Fundamentos y métodos”. Arturo de la Escalera. Prentice Hall, 2001

Copia para el alumno con fines didácticos

6.1. Detección de bordes.

Una de las informaciones más útiles que se encuentran en una imagen la constituyen los bordes ya que al delimitar los objetos definen los límites entre ellos y el fondo y entre los objetos entre sí. La información extraída por los detectores de bordes puede ser utilizada posteriormente en la etapa de segmentación. Las técnicas usadas en la detección de bordes tienen por objeto la localización de los puntos en que se produce una variación de intensidad -dónde se pasa del nivel de gris del fondo al del objeto- (figura 6.1), empleándose para ello métodos basados en los operadores derivada. Básicamente se tienen dos posibilidades: aplicar la primera (gradiente) o la segunda derivada (laplaciana). En el primer caso se buscarán grandes picos y en la segunda pasos de respuesta positiva a negativa o viceversa (paso por cero o *zero-crossing* en la literatura anglosajona). Como puede verse en la figura 6.1 se supone que el nivel de gris en el interior de los objetos es constante y, como ya se vio cuando se estudió la eliminación de ruido, es una situación que nunca se dará. Es por ello que después de la fase de detección de bordes viene otra que distingue lo que son los bordes del objeto de lo que es ruido. Para ello se supondrá que la respuesta de este último es mucho menor en amplitud que la de los bordes de los objetos por lo que se definirá un umbral mínimo para considerar un pixel como perteneciente a un borde. Ello llevará a que en el caso de los métodos basados en el gradiente la respuesta sea bordes de anchura mayor de un pixel, lo que introduce una incertidumbre en la verdadera localización de los bordes. Este inconveniente no se encuentra en los métodos que se basan en la segunda derivada ya que los bordes vienen definidos por el paso por cero. Sin embargo encontrar ese paso por cero no es algo inmediato por lo que los algoritmos serán más lentos que los que utilizan únicamente la primera derivada. Dependerá por tanto el que se necesite precisión o exactitud el que se elija un detector u otro.

6.1.1 Técnicas basadas en el gradiente.

Para poder utilizar operadores de este tipo sobre una imagen muestreada es necesario obtener una aproximación del concepto de derivada para espacios discretos. La generalización comúnmente usada se basa en el cálculo de diferencias entre pixeles vecinos. Estas diferencias, según la relación entre los pixeles considerados, pueden dar lugar a derivadas unidimensionales o bidimensionales, así como aplicarse en alguna dirección determinada de la imagen o en todas las direcciones de forma global. Existen otras aproximaciones diferenciales que han probado ser de gran utilidad para la extracción de contornos, es el caso de la de Roberts, la de Sobel, que se verán después.

Se define el operador gradiente G aplicado sobre una imagen $f(x,y)$ como:

$$\nabla f(x,y) = \begin{bmatrix} G_x & G_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} & \frac{\partial f}{\partial y} \end{bmatrix}$$

El vector gradiente representa la variación máxima de intensidad para el punto (x,y) . Es por ello interesante conocer su módulo y dirección que vendrán dados por:

$$|\nabla f| = \sqrt{G_x^2 + G_y^2}$$
$$\angle \nabla f = \arctan\left(\frac{G_y}{G_x}\right)$$

siendo la dirección del gradiente perpendicular al borde.

Debido al coste computacional el módulo a veces se simplifica por:

$$|\nabla f| = |G_x| + |G_y|$$

Como las imágenes digitales no son señales continuas sino discretas el gradiente se aproxima por:

$$\nabla f(x, y) = \begin{bmatrix} G_x & G_y \end{bmatrix} = \begin{bmatrix} \frac{\Delta f}{\Delta x} & \frac{\Delta f}{\Delta y} \end{bmatrix}$$

que se puede representar por las máscaras:

- $G_x = \frac{\Delta f}{\Delta x}$

$$\begin{bmatrix} -1 & 1 \end{bmatrix} * f(x, y)$$

- $G_y = \frac{\Delta f}{\Delta y}$

$$\begin{bmatrix} -1 \\ 1 \end{bmatrix} * f(x, y)$$

Sin embargo estas máscaras no suelen utilizarse debido a que son muy sensibles al ruido al tener en cuenta solamente la información de dos píxeles. Con el tiempo han aparecido otros filtros que además de calcular el gradiente tengan cierto efecto de suavizado, o lo que es lo mismo, sean menos sensibles al ruido.

Operador de Roberts.

0	-1
1	0

-1	0
0	1

Operador de Prewitt.

Expande la definición de gradiente a un entorno de 3x3 para ser más inmune al ruido.

-1	0	1
-1	0	1
-1	0	1

-1	-1	-1
0	0	0
1	1	1

Operador de Sobel

Sobel da más importancia a los píxeles centrales que el operador de Prewitt.

-1	0	1
-2	0	2
-1	0	1

-1	-2	-1
0	0	0
1	2	1

Operador Isotrópico (u operador de Frei-Chen).

Mientras que Prewitt detecta mejor los bordes verticales, Sobel lo hace en los diagonales. El operador isotrópico intenta llegar a un equilibrio entre ellos.

-1	0	1
----	---	---

-1	$-\sqrt{2}$	-1
----	-------------	----

$-\sqrt{2}$	0	$\sqrt{2}$
-1	0	1

0	0	0
1	$\sqrt{2}$	1

En la figura 6.2 se muestra la aplicación de estos operadores sobre la misma imagen. Quitando el operador de Roberts, claramente distinto a los otros tres, no se puede apreciar grandes diferencias en el resultado que proporcionan Prewitt, Sobel o Frei-Chen. Así, en la figura 6.3 se han tomado como puntos de borde aquellos pixeles superiores a cierto valor, siendo el de Roberts mucho menor que el de los otros tres. Aunque ahora sí que pueden verse resultados distintos aunque las diferencias no son muy grandes. Meramente por cuestión de costumbre el operador de Sobel es el que más se utiliza.

6.1.2 Operadores de segundo orden.

La laplaciana es la segunda derivada de una función y representa la derivada de esta respecto a todas las direcciones:

$$\nabla^2 f(x, y) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

Las dos definiciones que de forma más frecuente se utilizan para el operador Laplaciana son:

-1	-1	-1
-1	8	-1
-1	-1	-1

0	-1	0
-1	4	-1
0	-1	0

donde el pixel central toma el valor negativo de la suma de todos los que le rodean.

Como puede verse en la figura 6.4, este operador es muy sensible al ruido por lo que nunca se utiliza. Sin embargo si que es un paso intermedio para el operador de Marr-Hildreth que se considera a continuación.

6.1.3. Métodos basados en las derivadas de gaussianas.

El operador de Marr-Hildreth.

Según el desarrollo propuesto por Marr y Hildreth, el filtro que se utilice debe de cumplir dos condiciones.

1. Como se deben detectar los bordes, el filtro debe ser local y tomar solamente en cuenta la información de puntos cercanos al que se quiere analizar.
2. Desde el punto de vista frecuencial, debe de reducir el número de frecuencias que analiza, debe ser por tanto paso-banda.

Estas condiciones son contradictorias y el mejor compromiso es tomar la laplaciana de una gaussiana.

Si se convoluciona la imagen con una gaussiana de expresión:

$$G(x, y) = e^{-\frac{(x+y)^2}{2\sigma^2}}$$

se disminuye la influencia del ruido.

Si después se realiza la segunda deriva se obtiene el operador de Marr-Hildreth, también conocido como el operador laplaciana de una gaussiana o LoG:

$$H(x, y) = \nabla^2 (G(x, y) * I(x, y))$$

El operador así expresado primero haría la convolución de la imagen con la gaussiana para después obtener la laplaciana. Esto puede acelerarse ya que por propiedades de la gaussiana es lo mismo que:

$$H(x, y) = (\nabla^2 G(x, y)) * I(x, y)$$

siendo:

$$\begin{aligned}\nabla^2 &= \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2} \\ \frac{\partial G}{\partial x} &= -\frac{x}{\sigma^2} e^{\frac{-r^2}{2\sigma^2}} \\ \frac{\partial^2 G}{\partial x^2} &= -\frac{1}{\sigma^2} e^{\frac{-r^2}{2\sigma^2}} + \frac{x^2}{\sigma^4} e^{\frac{-r^2}{2\sigma^2}} = \frac{x^2 - \sigma^2}{\sigma^4} e^{\frac{-r^2}{2\sigma^2}}\end{aligned}$$

Luego:

$$\begin{aligned}\nabla^2 G(x, y) &= \frac{r^2 - 2\sigma^2}{\sigma^4} e^{\frac{-r^2}{2\sigma^2}} \\ r^2 &= x^2 + y^2\end{aligned}$$

En la figura 6.5 se tiene la imagen original, la convolución con una gaussiana de desviaciones típicas 1.8, 2.8 y 3.8 píxeles y la detección de bordes. Se puede ver la imagen original, la convolución con las gaussianas, la laplaciana y los bordes tras obtener el paso por cero. Obviamente cuanto más estrecha sea la gaussiana más bordes se obtendrán. De ello se desprende que si se tiene un juego de convoluciones se pueda ir de los bordes más importante de la imagen a los bordes que definen los objetos más pequeños o los detalles de los objetos. Este operador tiene los inconvenientes de encontrar más bordes de los necesarios si la gaussiana es estrecha (efecto *plato de espagueti*) y de redondear las esquinas.

De la figura 6.6 puede deducirse que la diferencia entre dos gaussianas (DoG) tiene una forma aproximada a la laplaciana. Por ello otra forma de obtener los bordes es convolucionar la imagen con dos gaussianas distintas, obtener su diferencia y buscar los puntos de paso por cero (figura 6.7).

Detector de Canny.

El detector de bordes de Canny se obtiene a partir de la optimización de una serie de condiciones:

- Error: Se deben detectar todos y solo los bordes.
 - Localización. La distancia entre el pixel señalado como borde y el borde real debe de ser tan pequeña como se pueda.
 - Respuesta. No debe identificar varios píxeles como bordes cuando sólo exista uno.
- Estas tres condiciones pueden ser expresadas de forma matemática como:

$$SNR = \frac{A \left| \int_{-W}^0 f(x) dx \right|}{n_0 \sqrt{\int_{-W}^W f^2(x) dx}}$$

$$\text{Localización} = \frac{A |f(0)|}{n_0 \sqrt{\int_{-W}^W f^2(x) dx}}$$

$$\text{Distancia} = \pi \left(\frac{\int_{-\infty}^{\infty} f^2(x) dx}{\int_{-\infty}^{\infty} f'^2(x) dx} \right)^{\frac{1}{2}}$$

Canny busca la optimización del producto de la relación señal ruido por la localización y el tercero como una condición. Con ello se llega a que el operador óptimo es la derivada de una gaussiana.

Para obtener los bordes se siguen los siguientes pasos:

- Se tiene la imagen I.
- Se tiene una gaussiana unidimensional G
- Se obtienen las derivadas (unidimensionales) de la gaussiana Gx y Gy
- Se convolucionan las derivadas de G con la imagen obteniendo Ix Iy (figura 6.8a) (figura 6.8b)
- Se obtiene la magnitud M como la raíz cuadrada de la suma de los cuadrados de Ix Iy (figura 6.8c).
- El siguiente paso es la supresión de aquellos pixeles que no sean máximos. Para ello se compara el valor de la magnitud para cada pixel con sus vecinos. Solo aquellos que son máximos en su entorno se dejan como están (figura 6.8d).
- Para detectar los bordes se utilizarán dos umbrales T1 y T2, siendo este último el mayor. Si se usase el menor (figura 6.8e) se detectarían bordes poco importantes, si se usase solo el mayor (figura 6.8f) se dejarían de detectar puntos pertenecientes a los bordes. Por ello la condición para pertenecer a un borde es ser mayor de T2 o mayor que T1 siempre que uno de sus vecinos sea mayor que T2 (figura 6.8g).

6.1.4. Operadores de ajuste al modelo.

Los operadores de ajuste al modelo permiten realizar una medida del gradiente en las direcciones seleccionadas. Se puede considerar las siguientes direcciones y sus máscaras asociadas:

	Prewitt	Kirsch	Robinson	Robinson																																				
Este	<table><tr><td>1</td><td>1</td><td>-1</td></tr><tr><td>1</td><td>-2</td><td>-1</td></tr><tr><td>1</td><td>1</td><td>-1</td></tr></table>	1	1	-1	1	-2	-1	1	1	-1	<table><tr><td>5</td><td>-3</td><td>-3</td></tr><tr><td>5</td><td>0</td><td>-3</td></tr><tr><td>5</td><td>-3</td><td>-3</td></tr></table>	5	-3	-3	5	0	-3	5	-3	-3	<table><tr><td>1</td><td>0</td><td>-1</td></tr><tr><td>1</td><td>0</td><td>-1</td></tr><tr><td>1</td><td>0</td><td>-1</td></tr></table>	1	0	-1	1	0	-1	1	0	-1	<table><tr><td>1</td><td>0</td><td>-1</td></tr><tr><td>2</td><td>0</td><td>-2</td></tr><tr><td>1</td><td>0</td><td>-1</td></tr></table>	1	0	-1	2	0	-2	1	0	-1
1	1	-1																																						
1	-2	-1																																						
1	1	-1																																						
5	-3	-3																																						
5	0	-3																																						
5	-3	-3																																						
1	0	-1																																						
1	0	-1																																						
1	0	-1																																						
1	0	-1																																						
2	0	-2																																						
1	0	-1																																						

Noreste	<table><tr><td>1</td><td>-1</td><td>-1</td></tr><tr><td>1</td><td>-2</td><td>-1</td></tr><tr><td>1</td><td>1</td><td>1</td></tr></table>	1	-1	-1	1	-2	-1	1	1	1	<table><tr><td>-3</td><td>-3</td><td>-3</td></tr><tr><td>5</td><td>0</td><td>-3</td></tr><tr><td>5</td><td>5</td><td>-3</td></tr></table>	-3	-3	-3	5	0	-3	5	5	-3	<table><tr><td>0</td><td>-1</td><td>-1</td></tr><tr><td>1</td><td>0</td><td>-1</td></tr><tr><td>1</td><td>1</td><td>0</td></tr></table>	0	-1	-1	1	0	-1	1	1	0	<table><tr><td>0</td><td>-1</td><td>-2</td></tr><tr><td>1</td><td>0</td><td>-1</td></tr><tr><td>2</td><td>1</td><td>0</td></tr></table>	0	-1	-2	1	0	-1	2	1	0
1	-1	-1																																						
1	-2	-1																																						
1	1	1																																						
-3	-3	-3																																						
5	0	-3																																						
5	5	-3																																						
0	-1	-1																																						
1	0	-1																																						
1	1	0																																						
0	-1	-2																																						
1	0	-1																																						
2	1	0																																						
Norte	<table><tr><td>-1</td><td>-1</td><td>-1</td></tr><tr><td>1</td><td>-2</td><td>1</td></tr><tr><td>1</td><td>1</td><td>1</td></tr></table>	-1	-1	-1	1	-2	1	1	1	1	<table><tr><td>-3</td><td>-3</td><td>-3</td></tr><tr><td>-3</td><td>0</td><td>-3</td></tr><tr><td>5</td><td>5</td><td>5</td></tr></table>	-3	-3	-3	-3	0	-3	5	5	5	<table><tr><td>-1</td><td>-1</td><td>-1</td></tr><tr><td>0</td><td>0</td><td>0</td></tr><tr><td>1</td><td>1</td><td>1</td></tr></table>	-1	-1	-1	0	0	0	1	1	1	<table><tr><td>1</td><td>-2</td><td>-1</td></tr><tr><td>0</td><td>0</td><td>0</td></tr><tr><td>1</td><td>2</td><td>1</td></tr></table>	1	-2	-1	0	0	0	1	2	1
-1	-1	-1																																						
1	-2	1																																						
1	1	1																																						
-3	-3	-3																																						
-3	0	-3																																						
5	5	5																																						
-1	-1	-1																																						
0	0	0																																						
1	1	1																																						
1	-2	-1																																						
0	0	0																																						
1	2	1																																						
Noroeste	<table><tr><td>-1</td><td>-1</td><td>1</td></tr><tr><td>-1</td><td>-2</td><td>1</td></tr><tr><td>1</td><td>1</td><td>1</td></tr></table>	-1	-1	1	-1	-2	1	1	1	1	<table><tr><td>-3</td><td>-3</td><td>-3</td></tr><tr><td>-3</td><td>0</td><td>5</td></tr><tr><td>-3</td><td>5</td><td>5</td></tr></table>	-3	-3	-3	-3	0	5	-3	5	5	<table><tr><td>-1</td><td>-1</td><td>0</td></tr><tr><td>-1</td><td>0</td><td>1</td></tr><tr><td>0</td><td>1</td><td>1</td></tr></table>	-1	-1	0	-1	0	1	0	1	1	<table><tr><td>-2</td><td>-1</td><td>0</td></tr><tr><td>-1</td><td>0</td><td>1</td></tr><tr><td>0</td><td>1</td><td>2</td></tr></table>	-2	-1	0	-1	0	1	0	1	2
-1	-1	1																																						
-1	-2	1																																						
1	1	1																																						
-3	-3	-3																																						
-3	0	5																																						
-3	5	5																																						
-1	-1	0																																						
-1	0	1																																						
0	1	1																																						
-2	-1	0																																						
-1	0	1																																						
0	1	2																																						
Oeste	<table><tr><td>-1</td><td>1</td><td>1</td></tr><tr><td>-1</td><td>-2</td><td>1</td></tr><tr><td>-1</td><td>1</td><td>1</td></tr></table>	-1	1	1	-1	-2	1	-1	1	1	<table><tr><td>-3</td><td>-3</td><td>5</td></tr><tr><td>-3</td><td>0</td><td>5</td></tr><tr><td>-3</td><td>-3</td><td>5</td></tr></table>	-3	-3	5	-3	0	5	-3	-3	5	<table><tr><td>-1</td><td>0</td><td>1</td></tr><tr><td>-1</td><td>0</td><td>1</td></tr><tr><td>-1</td><td>0</td><td>1</td></tr></table>	-1	0	1	-1	0	1	-1	0	1	<table><tr><td>-1</td><td>0</td><td>1</td></tr><tr><td>-2</td><td>0</td><td>2</td></tr><tr><td>-1</td><td>0</td><td>1</td></tr></table>	-1	0	1	-2	0	2	-1	0	1
-1	1	1																																						
-1	-2	1																																						
-1	1	1																																						
-3	-3	5																																						
-3	0	5																																						
-3	-3	5																																						
-1	0	1																																						
-1	0	1																																						
-1	0	1																																						
-1	0	1																																						
-2	0	2																																						
-1	0	1																																						
Sudoeste	<table><tr><td>1</td><td>1</td><td>1</td></tr><tr><td>-1</td><td>-2</td><td>1</td></tr><tr><td>-1</td><td>-1</td><td>1</td></tr></table>	1	1	1	-1	-2	1	-1	-1	1	<table><tr><td>-3</td><td>5</td><td>5</td></tr><tr><td>-3</td><td>0</td><td>5</td></tr><tr><td>-3</td><td>-3</td><td>-3</td></tr></table>	-3	5	5	-3	0	5	-3	-3	-3	<table><tr><td>0</td><td>1</td><td>1</td></tr><tr><td>-1</td><td>0</td><td>1</td></tr><tr><td>-1</td><td>-1</td><td>0</td></tr></table>	0	1	1	-1	0	1	-1	-1	0	<table><tr><td>0</td><td>1</td><td>2</td></tr><tr><td>-1</td><td>0</td><td>1</td></tr><tr><td>-2</td><td>-1</td><td>0</td></tr></table>	0	1	2	-1	0	1	-2	-1	0
1	1	1																																						
-1	-2	1																																						
-1	-1	1																																						
-3	5	5																																						
-3	0	5																																						
-3	-3	-3																																						
0	1	1																																						
-1	0	1																																						
-1	-1	0																																						
0	1	2																																						
-1	0	1																																						
-2	-1	0																																						
Sur	<table><tr><td>1</td><td>1</td><td>1</td></tr><tr><td>1</td><td>-2</td><td>1</td></tr><tr><td>-1</td><td>-1</td><td>-1</td></tr></table>	1	1	1	1	-2	1	-1	-1	-1	<table><tr><td>5</td><td>5</td><td>5</td></tr><tr><td>-3</td><td>0</td><td>-3</td></tr><tr><td>-3</td><td>-3</td><td>-3</td></tr></table>	5	5	5	-3	0	-3	-3	-3	-3	<table><tr><td>1</td><td>1</td><td>1</td></tr><tr><td>0</td><td>0</td><td>0</td></tr><tr><td>-1</td><td>-1</td><td>-1</td></tr></table>	1	1	1	0	0	0	-1	-1	-1	<table><tr><td>1</td><td>2</td><td>1</td></tr><tr><td>0</td><td>0</td><td>0</td></tr><tr><td>-1</td><td>-2</td><td>-1</td></tr></table>	1	2	1	0	0	0	-1	-2	-1
1	1	1																																						
1	-2	1																																						
-1	-1	-1																																						
5	5	5																																						
-3	0	-3																																						
-3	-3	-3																																						
1	1	1																																						
0	0	0																																						
-1	-1	-1																																						
1	2	1																																						
0	0	0																																						
-1	-2	-1																																						
Sudeste	<table><tr><td>1</td><td>1</td><td>1</td></tr><tr><td>1</td><td>-2</td><td>-1</td></tr><tr><td>1</td><td>-1</td><td>-1</td></tr></table>	1	1	1	1	-2	-1	1	-1	-1	<table><tr><td>5</td><td>5</td><td>-3</td></tr><tr><td>5</td><td>0</td><td>-3</td></tr><tr><td>-3</td><td>-3</td><td>-3</td></tr></table>	5	5	-3	5	0	-3	-3	-3	-3	<table><tr><td>1</td><td>1</td><td>0</td></tr><tr><td>1</td><td>0</td><td>-1</td></tr><tr><td>0</td><td>1</td><td>-1</td></tr></table>	1	1	0	1	0	-1	0	1	-1	<table><tr><td>2</td><td>1</td><td>0</td></tr><tr><td>1</td><td>0</td><td>-1</td></tr><tr><td>0</td><td>-1</td><td>-2</td></tr></table>	2	1	0	1	0	-1	0	-1	-2
1	1	1																																						
1	-2	-1																																						
1	-1	-1																																						
5	5	-3																																						
5	0	-3																																						
-3	-3	-3																																						
1	1	0																																						
1	0	-1																																						
0	1	-1																																						
2	1	0																																						
1	0	-1																																						
0	-1	-2																																						

Se ha de tener en cuenta que de las ocho máscaras anteriores sólo cuatro son linealmente independientes. Ello conduce a la posibilidad de definir cuatro matrices de 3x3 que sean mutuamente ortogonales y medir el espacio cubierto por ellas

6.4 Bibliografía.

- Canny, J. A computational approach to edge detection. *IEEE Transaction on pattern analysis and Machine Intelligence*, vol PAMI- 8 (6), pp 676-698, 1986.
- Marr, D. *Vision: a computational investigation into the human representation and processing of visual information*. 1982.
- Marr, D.; Hildreth, E. Theory of edge detection. *Proceedings of the Royal Society of London. Series B*, vol 207, pp 187-217, 1980.
- Prewitt, J., *Object enhancement and extraction. Picture processing and psychopictorics (B. Lipkin and A. Rosendfeld Eds)*. New York, Academic Press, 1970.
- Robinson, G.S. edge detection by compass gradient masks. *Computer Graphics and Image Processing* 6 (5): 492-501, 1977.
- Sobel, I.; *Camera Models and Machine Perception*. PhD Thesis, Stanford University, Stanford, CA, 1970.




Figura 6.1. Detección de bordes mediante la primera y la segunda derivada.



Roberts



Prewitt



Sobel



Isotrópico

Figura 6.2. Comparación entre los distintos detectores de bordes.



Roberts



Prewitt



Sobel



Isotrópico

Figura 6.3. Comparación entre los distintos detectores de bordes después de la umbralización.




Figura 6.4. Detección de bordes mediante la laplaciana.




Figura 6.5 Detección de bordes según Marr






Figura 6.6. (a) Laplaciana de una gaussiana (b) Diferencia de gaussianas.



Figura 6.7. Diferencia de gaussianas.



(a)



(b)



(c)



(d)

Figura 6.8 Detector de bordes de Canny.



(e)



(f)



(g)

Figura 6.8 (cont) Detector de bordes de Canny.